


Mineração Estatística de Dados
SME0878

Predição da Dificuldade de Questões do **ENEM**

Lucas Ciziks (12559472), Maria Vitória (12608692), Renan Gonzalez (6473399)




O contexto

O problema

O problema a ser enfrentado é a atual **dependência de pré-testes** para estimar os parâmetros psicométricos dos itens do Enem, o que envolve altos custos, complexidade logística e riscos à segurança e integridade do exame.

Busca-se, então, uma alternativa por meio do uso de ferramentas de Processamento de Linguagem Natural (PLN) para **prever a dificuldade dos itens a partir de características textuais**, contribuindo para a calibração prévia dos itens de forma mais eficiente, barata e segura.

Parâmetro B



Fonte: Brasil. Inep ([2012], p. 13).

Objetivo

Verificar a capacidade de predizer o **parâmetro de dificuldade** (parâmetro B) dos itens de Ciências da Natureza do Enem a partir de suas **características textuais**.

**Características
Textuais**



**Parâmetro B
(Dificuldade)**

Dados


- Questões de Ciências da Natureza das Provas de 2009 – 2016 (Variável Preditora);
- Questões de Ciências da Natureza das Provas LEDOR de 2017 a 2023 (Variável Preditora);
- Microdados do ENEM (Parâmetro de Dificuldade Real – *Ground Truth*).

Metodologia

1. Extração do Texto das Provas (Enunciado e Alternativas);
2. Cruzamento com Microdados (Gabarito e Dificuldade);
3. Pré-Processamento para *Tokenização*;
4. Transformação do Texto em *Embeddings*;
5. Extração de Features (LLM, Similaridade...)
6. Aplicação de Modelos de Regressão;



•[RegEx]*



Dicionário de Dados

Variáveis	Descrição
Número Questão	Número identificador da questão na prova
Enunciado	Texto do enunciado da questão
Gabarito	Letra da Alternativa correta (A, B, C, D ou E)
Distratores	Lista contendo os textos das alternativas incorretas
Enunciado_tokens	Lista de tokens (300 dimensões) extraídos do enunciado
Gabarito_tokens	Lista de tokens (300 dimensões) extraídos do texto do gabarito
Distratores_tokens	Lista de tokens (300 dimensões) de cada distrator individualmente
Dificuldade (Parâmetro B)	Valor numérico indicando a dificuldade da questão

Target

Features


Análise Exploratória

Resumo Estatístico

Estatística	Dificuldade (Parâmetro B)
Média	1.348
Desvio-padrão	0.9
Mínimo	-1.8
25,00%	0.8
50,00%	1.38
75,00%	1.85
Máximo	8.96

Análise Exploratória




Número de Questões Disponíveis



Total: 605 questões

Análise Exploratória

Análise da Dificuldade





Foi aplicado um teste Shapiro-Wilk, que **rejeitou** a hipótese de normalidade da distribuição do parâmetro B (p-valor ~ 0).

Possibilidade de aplicar Transformação Box-Cox

Análise Exploratória

Aplicando Filtro de $(-3, 3)$



O corte de dificuldade 3, sugerido e realizado no artigo motivador, não parece de todo arbitrário.

Análise Exploratória

Questão Mais Difícil

Questão 125

Grupos de pesquisa em todo o mundo vêm buscando soluções inovadoras, visando a produção de dispositivos para a geração de energia elétrica. Dentre eles, pode-se destacar as baterias de zinco-ar, que combinam o oxigênio atmosférico e o metal zinco em um eletrólito aquoso de caráter alcalino. O esquema de funcionamento da bateria zinco-ar está apresentado na figura.

Descrição da figura:

A figura apresenta uma célula eletroquímica formada por duas semicélulas separadas por uma membrana separadora.

A semicélula da esquerda contém um eletrodo poroso. Moléculas do gás oxigênio atravessam esse eletrodo e se transformam no íon OH^- de carga negativa. Há um fluxo de íons OH^- de carga negativa que atravessam a membrana separadora indo até a semicélula da direita, que contém um eletrodo de zinco, onde é formado o Zn(OH)_4^{2-} de carga 2^- . Essa célula eletroquímica está ligada a uma lâmpada através de dois fios: um que parte do eletrodo poroso e outro que parte do eletrodo de zinco. A lâmpada está acesa.

No funcionamento da bateria, a espécie química formada no ânodo é

- A H_2 (gasoso).
- B O_2 (gasoso).
- C H_2O (líquido).
- D OH^- de carga negativa (aquoso).
- E Zn(OH)_4^{2-} de carga 2^- (aquoso).

Ano: 2019

Dificuldade: 8.9

Questão Mais Fácil

QUESTÃO 88

Certas espécies de algas são capazes de absorver rapidamente compostos inorgânicos presentes na água, acumulando-os durante seu crescimento. Essa capacidade fez com que se pensasse em usá-las como biofiltros para a limpeza de ambientes aquáticos contaminados, removendo, por exemplo, nitrogênio e fósforo de resíduos orgânicos e metais pesados provenientes de rejeitos industriais lançados nas águas. Na técnica do cultivo integrado, animais e algas crescem de forma associada, promovendo um maior equilíbrio ecológico.

SORIANO, E. M. Filtros vivos para limpar a água. Revista Ciência Hoje. V. 37, n° 219, 2005 (adaptado).

A utilização da técnica do cultivo integrado de animais e algas representa uma proposta favorável a um ecossistema mais equilibrado porque




- A os animais eliminam metais pesados, que são usados pelas algas para a síntese de biomassa.
- B os animais fornecem excretas orgânicos nitrogenados, que são transformados em gás carbônico pelas algas.
- C as algas usam os resíduos nitrogenados liberados pelos animais e eliminam gás carbônico na fotossíntese, usado na respiração aeróbica.
- D as algas usam os resíduos nitrogenados provenientes do metabolismo dos animais e, durante a síntese de compostos orgânicos, liberam oxigênio para o ambiente.
- E as algas aproveitam os resíduos do metabolismo dos animais e, durante a quimiossíntese de compostos orgânicos, liberam oxigênio para o ambiente.

Ano: 2011

Dificuldade: -1.8

Análise Exploratória


Análise do Enunciado



Não se verifica uma correlação direta entre o tamanho do enunciado e a dificuldade da questão.



Análise Exploratória

Distribuição Gabarito



Análise Exploratória




Análise do Gabarito



Não se verifica uma correlação direta entre o tamanho do gabarito e a dificuldade da questão.

Análise Exploratória

Análise dos Distratores





Não se verifica uma correlação direta entre o tamanho do distrator e a dificuldade da questão.

Análise Exploratória

Nuvem de palavras



Enunciados



Análise Exploratória

Nuvem de palavras


Gabarito



Análise Exploratória

Nuvem de palavras

Distratores



Extração de Features LLMs

Modelo: Llama 3.2 (3B) 

Prompt:

Responda à seguinte questão:

Enunciado: {enunciado}

Alternativas: {alternativas}

Qual a alternativa correta? Responda apenas com a letra (A, B, C, D ou E).

Resultado: 28% de acerto (171 questões)

Próximos Passos

- Rodar LLMs mais robustos (DeepSeek, Gemma, Qwen...)
- Utilizar resultados como *Feature* da Regressão

Tokenização

- Vetorização utilizando modelo **Word2Vec** (300 dim)
 - Repositório de Word Embeddings do NILC;
- Tratamento dos textos para remover pontuações e *stopwords*;
- Transformação em cada palavra do texto (*Embeddings*);
- Vetor final = Média dos vetores de palavras
- Possibilidade: Testar para diferentes dimensões (50, 100...)

Regressão

- Input: Embeddings do Enunciado (300 dimensões)
- Normalização Box-Cox (Rejeição da Normalidade)
- Dataset completo e Dataset sem outliers
- Análise das métricas **R²** e **RMSE**
- Comparação com resultados relatados no artigo

Modelos de Regressão

Regressão Linear

Dataset completo

OLS Regression Results			
=====			
Dep. Variable:	y	R-squared:	0.749
Model:	OLS	Adj. R-squared:	0.131
Method:	Least Squares	F-statistic:	1.212
Date:	Mon, 28 Apr 2025	Prob (F-statistic):	0.111
Time:	13:15:41	Log-Likelihood:	-32.417
No. Observations:	423	AIC:	666.8
Df Residuals:	122	BIC:	1885.
Df Model:	300		
Covariance Type:	nonrobust		
=====			

RMSE: 0.97

Dataset Sem Outliers

OLS Regression Results			
=====			
Dep. Variable:	y	R-squared:	0.800
Model:	OLS	Adj. R-squared:	0.264
Method:	Least Squares	F-statistic:	1.492
Date:	Mon, 28 Apr 2025	Prob (F-statistic):	0.00718
Time:	15:45:46	Log-Likelihood:	-584.18
No. Observations:	413	AIC:	1770.
Df Residuals:	112	BIC:	2981.
Df Model:	300		
Covariance Type:	nonrobust		
=====			

RMSE: 3.88

Resultado do Artigo

A correlação entre o valor predito para os itens da base de teste e seu parâmetro de dificuldade foi 0,50. Ou seja, nosso modelo explica 25,2% da variância da dificuldade dos itens dessa base. O valor de R^2 superou a maioria dos valores obtidos por McCarthy et al. (2021),

Modelos de Regressão

Regressão Lasso

Dataset Completo

R2: 0.294

Alpha: 0.001

RMSE: 0.51

Dataset Sem Outliers

R2: 0.119

Alpha: 0.01

RMSE: 1.93

Resultado do Artigo

A correlação entre o valor predito para os itens da base de teste e seu parâmetro de dificuldade foi 0,50. Ou seja, nosso modelo explica 25,2% da variância da dificuldade dos itens dessa base. O valor de R^2 superou a maioria dos valores obtidos por McCarthy et al. (2021),

Modelos de Regressão

BERT


- ***BERTimbau*** – Tokenização e Modelo Pré-Treinado;
- Utilização dos Textos Originais;
- Arquitetura *Transformers (Encoder)* + Camada de Regressão;
- Aplicação do Otimizador *Adam*;
- 10 épocas treinadas (até o momento!)

```
print('Melhor RMSE treino:', min(rmse_list).cpu().detach().numpy())
```

```
Melhor RMSE treino: 0.23617610689463778
```


```
print('Melhor RMSE teste:', min(test_rmse_list).cpu().detach().numpy())
```

```
Melhor RMSE teste: 1.4179706871225115
```



Próximos Passos

- **Extração de Novas *Features***
 - "*Pré-teste*" em LLMs diferentes (DeepSeek, Qwen...);
 - Similaridade entre Enunciado/Gabarito/Distratores;
- **Melhorar Resultado das Regressões**
 - Testar *Embeddings* com diferentes dimensões (50, 100, 300);
 - Aplicar Vetores do Gabarito e Distratores;
 - Utilizar Novas *Features*.
- **Finalizar Relatório**

The image features a white background with the word "OBRIGADO!" centered in a bold, black, serif font. In the four corners, there are abstract, organic shapes in two shades of green (a darker forest green and a lighter sage green). Thin, wavy orange lines are also present, looping around the green shapes in the corners.

OBRIGADO!