



Mineração Estatística de Dados
SME0878

Predição da Dificuldade de Questões do **ENEM**

Lucas Ciziks (12559472), Maria Vitória (12608692), Renan Gonzalez (6473399)




ELABORAÇÃO DOS ITENS
O INEP REALIZA PARCERIAS COM PROFESSORES CREDENCIADOS EM CHAMADAS PÚBLICAS OU INSTITUIÇÕES DE EDUCAÇÃO SUPERIOR CREDENCIADAS INTERESSADAS EM ELABORAR E REVISAR ITENS PARA A COMPOSIÇÃO DAS PROVAS DO ENEM. O OBJETIVO DESSAS PARCERIAS É AUMENTAR A PARTICIPAÇÃO DA COMUNIDADE ACADÊMICA DE TODO O BRASIL NOS PROCESSOS DE AVALIAÇÃO EDUCACIONAL, AGREGANDO EXPERIÊNCIA, CONHECIMENTO E DIVERSIDADE.



BANCO NACIONAL DE ITENS (BNI)
É GERENCIADO PELO INEP E CONSISTE EM UM SISTEMA DE BANCO DE DADOS NO QUAL OS ITENS DE PROVAS SÃO ARMAZENADOS DE FORMA SEGURA. ESSES ITENS FICAM DISPONÍVEIS PARA A CONSTRUÇÃO DE PROVAS. A MANUTENÇÃO DO BNI DEPENDE DA ENTRADA CONSTANTE DE ITENS DE QUALIDADE.



PRÉ-TESTE
O PRÉ-TESTE CONSISTE NA APLICAÇÃO DE UM CONJUNTO DE ITENS A UMA AMOSTRA DE ALUNOS COM CARACTERÍSTICAS SEMELHANTES ÀS DA POPULAÇÃO PARA A QUAL A PROVA SE DESTINA. É A FORMA EMPÍRICA DE SE AVALIAR A QUALIDADE TÉCNICO-PEDAGÓGICA E PSICOMÉTRICA DOS ITENS. ESSA ETAPA TEM COMO OBJETIVO CAPTAR SUBSÍDIOS IMPORTANTES PARA AUMENTAR A PRECISÃO DA PROVA QUE SERÁ APLICADA A MILHÕES DE PARTICIPANTES DO ENEM.



ANÁLISE DEPOIS DO PRÉ-TESTE
A PARTIR DAS RESPOSTAS DOS ALUNOS, REALIZA-SE UMA SÉRIE DE ANÁLISES ESTATÍSTICAS E PEDAGÓGICAS; POR EXEMPLO, AVALIAM-SE A DIFICULDADE DO ITEM, A CAPACIDADE DE DISCRIMINAÇÃO E A POSSIBILIDADE DE ACERTO AO ACASO. DEPOIS DESSAS ANÁLISES, AS QUESTÕES QUE ATENDEM AOS CRITÉRIOS FICAM DISPONÍVEIS PARA A MONTAGEM DAS PROVAS, E AS DEMAIS QUESTÕES SÃO DESCARTADAS OU ENCAMINHADAS PARA REFORMULAÇÃO.

ELABORAÇÃO DAS PROVAS
DURANTE A SELEÇÃO DOS ITENS PARA A COMPOSIÇÃO DE UMA PROVA, OS ÍNDICES PSICOMÉTRICOS OBTIDOS A PARTIR DO PRÉ-TESTE SÃO UTILIZADOS. OUTRAS CARACTERÍSTICAS CONSIDERADAS SÃO: CONTEÚDO ABORDADO, TEMÁTICA E HABILIDADE DA MATRIZ DE REFERÊNCIA.



QUESTÃO ADEQUADA
ENCAMINHADA AO BANCO NACIONAL DE ITENS E UTILIZADA PARA A ELABORAÇÃO DAS PROVAS.

QUESTÃO INADEQUADA
RETORNA PARA REFORMULAÇÃO OU DESCARTE.




O contexto

O problema

O problema a ser enfrentado é a atual **dependência de pré-testes** para estimar os parâmetros psicométricos dos itens do Enem, o que envolve altos custos, complexidade logística e riscos à segurança e integridade do exame.

Busca-se, então, uma alternativa por meio do uso de ferramentas de Processamento de Linguagem Natural (PLN) para **prever a dificuldade dos itens a partir de características textuais**, contribuindo para a calibração prévia dos itens de forma mais eficiente, barata e segura.

Parâmetro B



Fonte: Brasil. Inep ([2012], p. 13).

- a) *parâmetro de discriminação*: é o poder de discriminação que cada questão possui para diferenciar os participantes que dominam dos participantes que não dominam a habilidade avaliada naquela questão (item);
- b) *parâmetro de dificuldade*: associado à dificuldade da habilidade avaliada na questão, quanto maior seu valor, mais difícil é a questão. Ele é expresso na mesma escala da proficiência. Em uma prova de qualidade, devemos ter questões de diferentes níveis de dificuldade para avaliar adequadamente os participantes em todos os níveis de conhecimento;
- c) *parâmetro de acerto casual*: em provas de múltipla escolha, um participante que não domina a habilidade avaliada em uma determinada questão da prova pode responder corretamente a um item devido ao acerto casual. Assim, esse parâmetro representa a probabilidade de um participante acertar a questão não dominando a habilidade exigida.

Objetivo

Verificar a capacidade de predizer o **parâmetro de dificuldade** (parâmetro B) dos itens de Ciências da Natureza do Enem a partir de suas **características textuais**.

**Características
Textuais**




**Parâmetro B
(Dificuldade)**

Dados

- Questões de Ciências da Natureza das Provas de 2009 – 2016 (Variável Preditora);
- Questões de Ciências da Natureza das Provas LEDOR de 2017 a 2023 (Variável Preditora);
- Microdados do ENEM (Parâmetro de Dificuldade Real – *Ground Truth*).

Metodologia

1. Extração do Texto das Provas (Enunciado e Alternativas);
2. Cruzamento com Microdados (Gabarito e Dificuldade);
3. Pré-Processamento para *Tokenização*;
4. Transformação do Texto em *Embeddings*;
5. Extração de Features (LLMs, Similaridade...)
6. Aplicação de Modelos de Regressão;



Dicionário de Dados

Variáveis	Descrição
Número Questão	Número identificador da questão na prova
Enunciado	Texto do enunciado da questão
Gabarito	Letra da Alternativa correta (A, B, C, D ou E)
Distratores	Lista contendo os textos das alternativas incorretas
PC_amostra_acertos	Porcentagem de acerto de uma amostra aleatória de 100 alunos da questão
Enunciado_tokens	Lista de tokens (300 dimensões) extraídos do enunciado
Gabarito_tokens	Lista de tokens (300 dimensões) extraídos do texto do gabarito
Distratores_tokens	Lista de tokens (300 dimensões) de cada distrator individualmente
Dificuldade (Parâmetro B)	Valor numérico indicando a dificuldade da questão

Target

Features


Análise Exploratória

Resumo Estatístico

Estatística	Dificuldade (Parâmetro B)
Média	1.348
Desvio-padrão	0.9
Mínimo	-1.8
25,00%	0.8
50,00%	1.38
75,00%	1.85
Máximo	8.96

Análise Exploratória


Questões Sem Parâmetro B



Total: 16 questões anuladas

Análise Exploratória




Número de Questões Disponíveis



Total: 605 questões

Análise Exploratória

Análise da Dificuldade





Foi aplicado um teste Shapiro-Wilk, que **rejeitou** a hipótese de normalidade da distribuição do parâmetro B (p-valor ~ 0).

Possibilidade de aplicar Transformação Box-Cox

Análise Exploratória

Aplicando Filtro de $(-3, 3)$



O corte de dificuldade 3, sugerido e realizado no artigo motivador, não parece de todo arbitrário.

Análise Exploratória

Questão Mais Difícil

Questão 125

Grupos de pesquisa em todo o mundo vêm buscando soluções inovadoras, visando a produção de dispositivos para a geração de energia elétrica. Dentre eles, pode-se destacar as baterias de zinco-ar, que combinam o oxigênio atmosférico e o metal zinco em um eletrólito aquoso de caráter alcalino. O esquema de funcionamento da bateria zinco-ar está apresentado na figura.

Descrição da figura:

A figura apresenta uma célula eletroquímica formada por duas semicélulas separadas por uma membrana separadora.

A semicélula da esquerda contém um eletrodo poroso. Moléculas do gás oxigênio atravessam esse eletrodo e se transformam no íon OH de carga negativa. Há um fluxo de íons OH de carga negativa que atravessam a membrana separadora indo até a semicélula da direita, que contém um eletrodo de zinco, onde é formado o Zn(OH)_4 de carga 2^- . Essa célula eletroquímica está ligada a uma lâmpada através de dois fios: um que parte do eletrodo poroso e outro que parte do eletrodo de zinco. A lâmpada está acesa.

No funcionamento da bateria, a espécie química formada no ânodo é

- A** H_2 (gasoso).
- B** O_2 (gasoso).
- C** H_2O (líquido).
- D** OH de carga negativa (aquoso).
- E** Zn(OH)_4 de carga 2^- (aquoso).

Ano: 2019

Dificuldade: **8.9**

Questão Mais Fácil

QUESTÃO 88

Certas espécies de algas são capazes de absorver rapidamente compostos inorgânicos presentes na água, acumulando-os durante seu crescimento. Essa capacidade fez com que se pensasse em usá-las como biofiltros para a limpeza de ambientes aquáticos contaminados, removendo, por exemplo, nitrogênio e fósforo de resíduos orgânicos e metais pesados provenientes de rejeitos industriais lançados nas águas. Na técnica do cultivo integrado, animais e algas crescem de forma associada, promovendo um maior equilíbrio ecológico.

SORIANO, E. M. Filtros vivos para limpar a água. Revista Ciência Hoje. V. 37, n° 219, 2005 (adaptado).

A utilização da técnica do cultivo integrado de animais e algas representa uma proposta favorável a um ecossistema mais equilibrado porque




- A** os animais eliminam metais pesados, que são usados pelas algas para a síntese de biomassa.
- B** os animais fornecem excretas orgânicos nitrogenados, que são transformados em gás carbônico pelas algas.
- C** as algas usam os resíduos nitrogenados liberados pelos animais e eliminam gás carbônico na fotossíntese, usado na respiração aeróbica.
- D** as algas usam os resíduos nitrogenados provenientes do metabolismo dos animais e, durante a síntese de compostos orgânicos, liberam oxigênio para o ambiente.
- E** as algas aproveitam os resíduos do metabolismo dos animais e, durante a quimiossíntese de compostos orgânicos, liberam oxigênio para o ambiente.

Ano: 2011

Dificuldade: **-1.8**

Análise Exploratória


Análise do Enunciado



Não se verifica uma correlação direta entre o tamanho do enunciado e a dificuldade da questão.



Análise Exploratória

Distribuição Gabarito



Análise Exploratória




Análise do Gabarito



Não se verifica uma correlação direta entre o tamanho do gabarito e a dificuldade da questão.

Análise Exploratória

Análise dos Distratores





Não se verifica uma correlação direta entre o tamanho do distrator e a dificuldade da questão.

Análise Exploratória

Nuvem de palavras


Enunciados



Análise Exploratória

Nuvem de palavras


Gabarito



Análise Exploratória

Nuvem de palavras

Distratores





Tokenização

- Vetorização utilizando modelo **Word2Vec** (300 dim)
 - Repositório de Word Embeddings do NILC;
 - 300, 100 e 50 dimensões aplicadas
- Tratamento dos textos para remover *stopwords*;
- Transformação em cada palavra do texto (*Embeddings*);
- Vetor final = Média dos vetores de palavras

	1	2	3	4	...	299	300
água →	0.1	-0.8	0.6	0.1	...	-0.7	0.4
energia →	0.2	0.4	-0.1	0.1	...	0.2	-0.1
=							
	0.15	-0.2	0.25	0.1	...	-0.25	0.15

Cálculo das Similaridades



"Nuvem" Central de Enunciado → Semanticamente Similares
Distratores e Gabaritos Dispersos → Possível Discriminação

"Pré-Teste" em LLMs

Llama-3.2


Quantidade de acertos: 171

Taxa de acertos: **28%**

DeepSeek-R1

Quantidade de acertos: 399

Taxa de acertos: **66%**




Dicionário de Dados

Feature
Original



Variáveis	Descrição
Enunciado_tokens	Lista de tokens (300 dimensões) extraídos do enunciado
Similaridade Enunciado/Gabarito	Similaridade de Cosseno entre os vetores do Enunciado e Gabarito
Similaridade Enunciado/Distratores	Similaridade de Cosseno entre os vetores do Enunciado e Distratores
Similaridade Gabarito/Distratores	Similaridade de Cosseno entre os vetores do Gabarito e Distratores
PC_amostra_acertos	Porcentagem de acerto de uma amostra aleatória de 100 alunos da questão
Acerto_Llama	Variável Binária de Acerto do Llama3.2 (True ou False)
Acerto_DeepSeek	Variável Binária de Acerto do DeepSeek-R1 (True ou False)
Dificuldade (Parâmetro B)	Valor numérico indicando a dificuldade da questão



Novas
Features

Target



Regressão

- *Input:*
 - Embeddings do Enunciado (300/100/50 dim);
 - Acertos DeepSeek/Llama (True ou False);
 - % de Acertos Alunos (Amostra aleatória)
 - Similaridade entre Enunciado/Gabarito/Distratores
- *Output:* Dificuldade (Parâmetro B)
- Normalização Box-Cox (Rejeição da Normalidade)
- Análise das métricas **R²** e **RMSE**
- Corte sugerido pelo artigo com resultados piores

A correlação entre o valor predito para os itens da base de teste e seu parâmetro de dificuldade foi 0,50. Ou seja, nosso modelo explica 25,2% da variância da dificuldade dos itens dessa base. O valor de R^2 superou a maioria dos valores obtidos por McCarthy et al. (2021),


Regressão

Modelos		Métricas					
		300 dimensões		100 dimensões		50 dimensões	
		RMSE	R2	RMSE	R2	RMSE	R2
Regressão Linear	Enunciado Embeddings	0.976	0.131	0.585	0.134	0.535	0.116
	LLM + Similaridade Features	0.843	0.330	0.516	0.341	0.464	0.335
Regressão Lasso	Enunciado Embeddings	0.510	0.300	0.507	0.197	0.498	0.156
	LLM + Similaridade Features	0.436	0.446	0.431	0.390	0.419	0.360

Modelos de Regressão


BERT

- ***BERTimbau*** – Tokenização e Modelo Pré-Treinado;
- Utilização dos Textos Originais (Somente Enunciado);
- Arquitetura *Transformers (Encoder)* + Camada de Regressão;
- Aplicação do Otimizador *Adam*;
- 10 e 100 épocas treinadas




Modelos de Regressão

BERT - Resultados



RMSE Treino: 0.236

RMSE Teste: **1.417**




RMSE Treino: 0.150

RMSE Teste: **0.97**

Problema: Poucos Dados para Fine-Tuning (*Overfitting*)

Conclusão

- Construção de Dataset Estruturado com mais de uma década de questões, alternativas e parâmetros do ENEM;
- Regressões com *embeddings* de 50 e 100 dimensões apresentaram performance superior ao de 300;
- Modelos com Regularização Lasso foram eficazes na redução do erro absoluto (Utilidade em contextos de alta dimensionalidade);
- Corte sugerido pelo artigo motivador prejudicou a performance;
- Inclusão de covariáveis de similaridade semântica e acerto dos LLMs resultou em melhora considerativa do modelo;
- Para melhor proveito do BERT Regressor, é preciso de mais dados (>100k)

The image features a white background with the word "OBRIGADO!" centered in a bold, black, serif font. In the four corners, there are abstract decorative elements consisting of overlapping green shapes in two shades (a darker forest green and a lighter sage green) and thin, flowing orange lines that create a sense of movement and organic form.

OBRIGADO!