

UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação
Departamento de Estatística.

Lucas Ivars Cadima Ciziks¹
Maria Victoria Brandao Barros²
Renan Gonzales³

¹ *Nº USP: 12559472 e-mail: luciziks@usp.br*

² *Nº USP: 12608692 e-mail: mariabrandaob@usp.br*

³ *Nº USP: 6473399 e-mail: renan.gonzales@usp.br*

**Predição da Dificuldade de Questões do ENEM a partir de
suas Características Textuais**

São Carlos

2025

Lucas Ivars Cadima Ciziks¹
Maria Victoria Brandao Barros²
Renan Gonzales³

¹ *Nº USP: 12559472 e-mail: luciziks@usp.br*

² *Nº USP: 12608692 e-mail: mariabrandaob@usp.br*

³ *Nº USP: 6473399 e-mail: renan.gonzales@usp.br*

Predição da Dificuldade de Questões do ENEM a partir de suas Características Textuais

Relatório entregue como parte dos
requisitos de avaliação na disciplina de
Mineração Estatística do Instituto de
Ciências Matemáticas e de Computação da
Universidade de São Paulo - ICMC/USP.

Professora: Mariana Cúri

Versão original

São Carlos
2025

SUMÁRIO

1	INTRODUÇÃO	5
2	METODOLOGIA	8
2.1	Extração dos Enunciados	8
2.2	Cruzamento com os Microdados	9
2.3	Pré-Processamento Textual	9
2.4	Análise Exploratória	10
2.5	Vetorização dos Enunciados	10
2.6	Engenharia de Covariáveis com uso de LLMs	11
2.7	Inclusão da Variável de Percentual de Acertos	12
2.8	Cálculo de Similaridades entre Embeddings	13
2.9	Modelagem Preditiva	13
3	ANÁLISE EXPLORATÓRIA	15
3.1	Distribuição do Parâmetro de Dificuldade	15
3.2	Verificação de Normalidade	16
3.3	Questões por Ano de Aplicação	17
3.4	Distribuição das Alternativas Corretas	18
3.5	Distribuição do Tamanho dos Enunciados e Gabaritos	19
3.6	Relação entre Tamanho e Dificuldade	20
3.7	Frequência e Padrões de Palavras	20
3.8	Nuvens de Palavras por Dificuldade	21
4	MODELOS E RESULTADOS	23
4.1	Compreensão de conceitos: R^2 e $RMSE$	23
4.1.1	Definições	23
4.1.2	Comparação Conceitual	23
4.1.3	Limitações e Uso Conjunto	24
4.2	Modelos de Regressão com <i>Word Embeddings</i>	24
4.2.1	Base Integral e Sem Estudo de Similaridades	24
4.2.2	Modelos com Exclusão de Outliers e Sem Estudo de Similaridades	25
4.2.3	Modelos com Similaridades Semânticas e Acertos do LLM	26
4.3	Modelo <i>BERT</i> regressor	27
4.3.1	Construção e funcionamento do modelo	27
4.3.2	Resultados	28
5	CONCLUSÃO	29

REFERÊNCIAS 31

1 INTRODUÇÃO

Trata-se de trabalho de Mineração Estatística proposto pela professora Mariana Cúri. Nos termos em que proposto, o presente teria como escopo a reexecução da metodologia proposta por Jaloto *et al.* (2023). Mais especificamente, este trabalho investiga a possibilidade de prever o parâmetro de dificuldade (b) de itens do ENEM a partir de suas características textuais, empregando, para isso, representações vetoriais do enunciado das questões, conhecidas como *word embeddings*. Ainda de acordo com o estudo base, vetores pré-treinados do tipo Word2Vec foram utilizados para representar semanticamente os termos das questões da área de Ciências da Natureza, obtendo-se uma correlação de 0,50 entre as previsões e os valores empíricos do parâmetro b . Invariavelmente, tais resultados se prestam como orientações para o presente trabalho, de modo que será possível entender premissas adotadas e possibilidades de melhorias na modelagem dos dados.

Sobre o objeto do estudo, observa-se que a aplicação de testes educacionais em larga escala no Brasil, como o Exame Nacional do Ensino Médio (ENEM), envolve desafios não desprezíveis relacionados à mensuração e comparabilidade de resultados, o que fica evidente pelo tempo de disponibilização do resultado final. Tradicionalmente, o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (2021) (INEP) utiliza a Teoria de Resposta ao Item (TRI), para calibrar os itens com base em pré-testagens - mais especificamente o logístico de três parâmetros (3PL) (JALOTO *et al.*, 2023). Contudo, faz-se necessário observar o fato de esse processo exigir recursos operacionais elevados, afinal a exposição prévia de um item compromete sua validade, de modo que se torna inviável obter o grau de dificuldade da pergunta a priori. Como alternativa metodológica, todavia, há possibilidade de abordagens baseadas em técnicas de Processamento de Linguagem Natural (PLN). Desta maneira, o intuito de estimar a dificuldade de um item a partir de suas características textuais, antes mesmo de sua aplicação empírica, não é mais algo inviável. Em outras palavras, acaso obtido um modelo suficientemente seguro, haveria uma maior possibilidade de controle de dificuldade da prova em cada.

O artigo base para o presente estudo demonstra a tentativa de ampliação dessa linha de investigação, analisando questões de ciências da natureza das provas do ENEM aplicadas entre os anos de 2009 e 2020, perfazendo, aproximadamente, 600 questões. Entretanto, como abordagem, optaram por excluir dificuldades extremas, como as maiores do que 3 ou inferiores a -3 — não há explicação técnica sobre a escolha. Ainda sobre a etapa preparatória, assim como dito anteriormente, a variável *target* foi o denominado *parâmetro B*. Efetivado o recorte temporal e de objetivos, os autores elaboraram um modelo de regressão linear da vetorização dos enunciados (de 300 dimensões, para ser mais preciso), tomando como base o disponibilizado por Hartmann *et al.* (2017), excluindo

números, *stop words* e palavras repetidas. Enfim, separado um conjunto de treino de 80%, utilizaram o pacote *tidymodels* para a concretização da regressão e, assim, obter a métrica visada pelo artigo R^2 - no caso concreto, obtiveram 25%, contudo não houve explicação se foi o ajustado, ou não.

Deste ponto de partida, o presente trabalho se atentará às provas elaboradas de 2009 a 2023, com especial atenção às edições datadas de 2017 em diante por apresentarem um diferencial de acessibilidade: são adaptadas ao formato LEDOR (Figura 2), metodologia consistente pela leitura dos textos das questões por um profissional para os participantes com deficiência visual. A razão por trás de tal escolha metodológica se deu a fim de evitar perda de informações presentes em figuras, que trariam uma complexidade a mais para vetorização do enunciado. Em outras palavras, enunciados a partir de 2017 tendem a ser mais ricos para o modelo de predição, uma vez que serão capazes de padronizar conteúdos imagéticos e de semiótica.

QUESTÃO 116

O ciclo do nitrogênio é composto por várias etapas, conforme a figura, sendo cada uma desempenhada por um grupo específico de microrganismos.

```

graph TD
    GN[Gás nitrogênio] -- 1 --> A[Amônia]
    D[Detritos] -- 2 --> A
    A -- 3 --> N[Nitrito]
    N -- 4 --> NR[Nitrato]
    NR -- 5 --> GN
  
```

Se o grupo dos microrganismos decompositores fosse exterminado, qual etapa não ocorreria?

A 1
B 2
C 3
D 4
E 5

Figura 1 – Enunciado da prova regular.

QUESTÃO 111

O ciclo do nitrogênio é composto por várias etapas, conforme a figura, sendo cada uma desempenhada por um grupo específico de microrganismos.

Descrição da figura: Gás nitrogênio é convertido em amônia por microrganismos do grupo 1. Detritos são convertidos em amônia por microrganismos do grupo 2. Amônia é convertida em nitrito por microrganismos do grupo 3. Nitrito é convertido em nitrato por microrganismos do grupo 4. Nitrato é convertido em gás nitrogênio por microrganismos do grupo 5.

```

graph TD
    GN[Gás nitrogênio] -- 1 --> A[Amônia]
    D[Detritos] -- 2 --> A
    A -- 3 --> N[Nitrito]
    N -- 4 --> NR[Nitrato]
    NR -- 5 --> GN
  
```

Se o grupo dos microrganismos decompositores fosse exterminado, qual etapa não ocorreria?

A 1
B 2
C 3
D 4
E 5

Figura 2 – Enunciado da prova LEDOR.

Computacionalmente, é inevitável verificar que as representações vetoriais de palavras — ou *embeddings* — constituem uma das mais relevantes contribuições do PLN moderno. Vetores densos em espaço contínuo, como Word2Vec, GloVe e FastText,

capturam relações semânticas e sintáticas entre palavras a partir de grandes corpora textuais. Contudo, também é possível notar as limitações que trazem consigo, ao tratar de forma muito mais localizada e com pouca contextualização geral. Assim, mais recentemente, modelos como o BERT (DEVLIN *et al.*, 2019) (Bidirectional Encoder Representations from Transformers), que operam em nível contextualizado, têm demonstrado avanços substanciais em tarefas linguísticas diversas, incluindo a representação semântica de sentenças completas. Neste estudo, portanto, também não se perde de vista a possibilidade de explorar tanto embeddings estáticos quanto embeddings contextuais como base para modelagem da dificuldade dos itens.

Já com relação à modelagem preditiva, esta é conduzida por meio de regressões lineares e não-lineares, com o objetivo de investigar a capacidade das representações textuais em estimar o parâmetro b dos itens com base apenas nos seus enunciados. Todavia, por óbvio, deve-se reconhecer que regressões lineares, por sua simplicidade e interpretabilidade, servem como modelo base, enquanto arquiteturas mais robustas — como regressões com regularização e redes neurais — podem ser exploradas em trabalhos futuros para aperfeiçoamento da performance.

Além disso, pretende-se investigar a contribuição de diferentes dimensões semânticas dos embeddings no aumento ou redução da dificuldade estimada. Com base em nuvens de palavras e análise de coeficientes, busca-se, assim, identificar que tipos de vocabulário (científico, cotidiano, técnico etc.) são mais associados a itens fáceis ou difíceis. A identificação dessas relações pode informar práticas de elaboração de itens, contribuindo para exames cuja dificuldade *a priori* não seja apenas intuitiva, mas objetivamente quantificável. Para além disso, haveria a possibilidade, até mesmo, de maiores compreensões em campos de conhecimento acadêmico em que a computação ainda não é tão difundida, como licenciatura e pedagogia.

Por fim, este trabalho objetiva reproduzir o artigo original elaborado por Jaloto *et al.* (2023) e, também, analisar a viabilidade de predição da dificuldade dos itens do ENEM utilizando somente informações textuais, sem o uso de pré-testes ou respostas de candidatos, porém com outras metodologias. Restrito a essas possibilidades, pretende-se fornecer subsídios para a disponibilização de provas mais padronizadas, além de possibilitar eventual colaboração com outros campos acadêmicos. Tudo explorando o potencial do processamento de linguagem natural na avaliação educacional.

2 METODOLOGIA

Melhor detalhando o que já descrito na introdução, o presente estudo foi desenvolvido a partir de uma abordagem empírica e computacional, estruturada em múltiplas etapas, cada qual implementada em notebooks Python no formato `.ipynb`. Como base para análise, foram tomadas apenas as questões de ciências da natureza das provas do Exame Nacional do Ensino Médio (ENEM) entre os anos de 2009 e 2023, sendo as edições de 2017 a 2023 adaptadas para aplicação com recurso de leitura por leitor.

Tendo em mente o fato de o ENEM disponibilizar diversas versões de provas, com alteração da ordem de cada questão, o presente trabalho foca apenas nas provas da cor Azul (quando da aplicação regular) e Laranja (prova de versões LEDOR).

Observa-se que o repositório com todos os códigos está disponibilizado publicamente em <https://github.com/ciziks/enem-word-embeddings>.

A seguir, descreve-se detalhadamente cada etapa do processo metodológico.

2.1 Extração dos Enunciados

O primeiro passo a ser tomado é exatamente a etapa mais morosa do presente trabalho. Isso porque, apesar de as provas e microdados estarem disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (2025), não há padronização na disponibilização dos arquivos `.pdf`. Ou seja, enquanto alguns são disponibilizados em formato texto, outros possuem palavras encriptadas ou como figuras.

A fim de minimamente padronizar a extração de enunciados, foi utilizado o notebook **1. Extração dos Enunciados.ipynb**. Por ali estão disponibilizados scripts para a coleta e extração dos enunciados de questões ENEM a partir de cadernos oficiais de prova. Para tanto, utilizou-se o pacote `PyMuPDF` para extração do texto bruto (*string*) dos arquivos PDF—anos de 2015, 2016, 2018, 2019, 2020, 2022 e 2023—, porém também foi necessário o uso da biblioteca open-source `pytesseract` para aplicar OCR nas edições cuja qualidade digital impedia a extração direta — anos de 2017 e 2021. Tudo sem prejuízo de extrações manuais — anos de 2009 a 2014.

Ato contínuo, implementou-se um *parser* para isolar blocos textuais correspondentes aos enunciados, bem como às alternativas (A a E), associando-os aos respectivos anos e números de questão. Como resultado, obteve-se uma base de dados textual estruturada contendo os enunciados limpos e identificados.

2.2 Cruzamento com os Microdados

O notebook **2. Cruzamento Microdados.ipynb**, por sua vez, tem como objetivo associar enunciados extraídos aos parâmetros psicométricos disponibilizados nos microdados do INEP, com destaque para o parâmetro b da Teoria da Resposta ao Item (TRI), além do gabarito oficial. Ainda, utilizam-se filtros para selecionar apenas os itens da área de Ciências da Natureza. O cruzamento foi realizado com base no número da questão, ano da prova e área do conhecimento, resultando em um conjunto final com enunciado textual e valor empírico de dificuldade.

Entretanto, importa ressaltar particularidade sobre as provas de 2016 e 2017, uma vez que os microdados apenas contam com a posição das questões dentro da área de estudo, e não necessariamente sua localização na prova propriamente dita. Ou seja, trata-se da primeira questão de Ciências da Natureza, de modo os microdados lhe rotularizaram como índice 1, contudo na prova é a questão 91.

2.3 Pré-Processamento Textual

No notebook **3. Pré-Processamento.ipynb**, por conseguinte, aplicou-se uma sequência de transformações linguísticas sobre os textos dos enunciados: conversão para letras minúsculas, remoção de pontuação, exclusão de *stopwords*¹, remoção de números e lematização². Também foram eliminadas palavras duplicadas dentro de cada item, de modo a reduzir o ruído nas representações vetoriais posteriores.

Como padronização, também foram eliminadas questões cujas alternativas são vazias (devido à presença exclusiva de imagens ou de números). Ainda, criou-se coluna de gabarito, que contém texto oficial da alternativa declarada como correta pelo INEP, e de distratores, alternativas incorretas.

O objetivo desta etapa foi padronizar os dados para a fase de vetorização, garantindo consistência na semântica dos termos representados, além de distinção do papel que cada alternativa tem na prova.

Para visualização, segue dicionário de dados:

- **Numero_questao** — Número identificador da questão na prova.
- **Enunciado** — Texto completo do enunciado da questão, em sua forma original.
- **Alternativas** — Cadeia de caracteres contendo todas as alternativas da questão, no formato: A: ...; B: ...; C: ...; D: ...; E:

¹ Utilizada a biblioteca **nlTK** em português como padronização

² Também com **nlTK** em português como padronização

- **Gabarito** — Letra da alternativa correta, podendo assumir os valores A, B, C, D ou E.
- **Ano** — Ano de aplicação da prova correspondente à questão.
- **Gabarito_texto** — Texto integral da alternativa correta, extraído a partir da letra do gabarito e do campo **Alternativas**.
- **Distratores** — Lista contendo os textos das alternativas incorretas, em formato de `list` com quatro elementos.
- **Enunciado_tokens** — Lista de tokens extraídos do campo **Enunciado**, após o pré-processamento textual (minúsculas, remoção de stopwords, pontuação e normalização).
- **Gabarito_tokens** — Lista de tokens extraídos do campo **Gabarito_texto**, utilizando os mesmos critérios de pré-processamento do enunciado.
- **Distratores_tokens** — Lista de listas, contendo os tokens de cada distrator de forma individual, após o pré-processamento.
- **Dificuldade** (variável *target*) — Valor numérico do parâmetro de dificuldade (*b*) associado à questão, obtido por meio dos microdados do Enem.

2.4 Análise Exploratória

Para melhor familiarização com os dados, o notebook **4. Análise Exploratória.ipynb** reuniu estatísticas descritivas sobre a base textual e os parâmetros de dificuldade. Analisou-se variáveis como o tamanho dos enunciados (em caracteres e palavras), a distribuição do parâmetro *b* ao longo dos anos e a relação entre o tamanho dos textos e a dificuldade associada. Histogramas, boxplots e gráficos de dispersão foram empregados para investigar tendências, outliers e padrões preliminares nos dados.

Para melhor familiarização, haverá capítulo dedicado ao tema, com exposição de gráficos e entendimentos obtidos.

2.5 Vetorização dos Enunciados

A vetorização dos textos foi conduzida no notebook **5. Tokenização.ipynb**. Utilizou-se a média dos vetores de *word embeddings* pré-treinados (modelo do NILC - Hartmann *et al.* (2017)), com 300 dimensões, para representar cada item. Cada palavra foi substituída por seu vetor correspondente e, em seguida, calculou-se a média vetorial do enunciado. Rememorando que essa abordagem, conhecida como *mean pooling*, foi escolhida a fim de emular as condições originais propostas no artigo base. O resultado dessa etapa foi uma matriz numérica de dimensão $n \times 300$, onde n é o número de itens.

Aqui, contudo, importa observar certa limitação no método utilizado. Isso porque, muito embora a biblioteca de vetorização seja, de fato, bastante abrangente, ainda não o é de forma absoluta. Ou seja, 155 (cento e cinquenta e cinco) palavras não foram vetorizadas por estarem ausentes na base NILC. As razões para isso se encontram na alta especificidade e variação de cada palavra, dado que podem ser extremamente técnicas ou específicas ao contexto científico.³ Muito embora sejam de baixa frequência ao longo dos anos, é importante ressaltar suas ausências.

Ainda, a partir deste momento passou-se a utilizar arquivos no formato `.pkl` (*Pickled Python Objects*), dada a melhora de performance ao trabalhar com vetores — usualmente utilizado pelo `scikit-learn`, armazena dados de maneira mais otimizada para a linguagem *Python*.

2.6 Engenharia de Covariáveis com uso de LLMs

Com vista a enriquecer as análises e expandir as abordagens além da vetorização por *word embeddings*, foi conduzido um experimento adicional com modelos de linguagem de larga escala (LLMs). Visa-se, assim, avaliar a capacidade desses modelos em resolver as questões do ENEM e, a partir disso, construir uma variável binária indicativa de acerto (`LLM_acerto = True/False`).

A motivação para essa abordagem se ancora em dois pilares centrais discutidos na literatura recente.

Primeiramente, conforme propõe Yaneva *et al.* (2024), a capacidade de LLMs preverem a dificuldade de questões pode ser sensivelmente aprimorada ao observar seu próprio desempenho na resolução das mesmas. Em outras palavras, a taxa de acerto de um modelo em questões reais pode ser utilizada como *proxy* de percepção de dificuldade, constituindo uma fonte adicional de informação para inferência. Ainda que o artigo mencionado trate de contextos clínicos, importa observar que sua metodologia é facilmente extensível para o presente estudo.

Em segundo lugar, o framework LLaSA (*LLMs are Students at Various Levels*), apresentado por Park *et al.* (2024), propõe uma simulação de diferentes níveis de proficiência estudantil a partir do emprego de diversos modelos de LLM. Sobre esta base, a resposta dada por um LLM a uma questão assumiria valor informativo sobre a dificuldade percebida por aquele “perfil simulado” de estudante. Em outras palavras, aplicar um “pré-teste” para diferentes LLMs pode ser útil na predição da dificuldade. Tal suposição apresenta forte potencial de uso, na medida em que permitiria estimar dificuldades sem que haja respostas humanas e, por consequência, minoraria riscos de vazamento.

Com base nesses fundamentos, o presente trabalho emulará o processo mencionado,

³ Como exemplos, possível citar “antifilica”, “catalisem”, “monofluoracético” etc.

mas com ressalvas dada a limitação tecnológica. Para isso, foi utilizado o ***ollama*** para rodar dois LLMs diferentes localmente: Llama3.2B (GRATTAFIORI; DUBEY; JAUHRI, 2024) e DeepSeek-R1-7B-Qwen (GUO *et al.*, 2025). Assim, serão utilizadas variáveis que assumirão valor 1 caso o modelo retorne como resposta a alternativa oficialmente correta e 0 caso contrário. Ou seja, obtida a partir da inferência direta de uma LLM sobre o item, com prompt padronizado e replicável, conforme detalhado em seção específica. Dessa forma, busca-se não apenas enriquecer a modelagem preditiva, mas também abrir caminho para estudos futuros sobre divergência entre dificuldade empírica e dificuldade percebida por modelos.

Vale destacar que essa abordagem, em ambientes ideais, fornece flexibilidade analítica para:

- Verificar se há relação entre acerto da LLM e o parâmetro empírico de dificuldade (b);
- Aplicar a lógica de classificação, simulando LLMs como estudantes de diferentes níveis (como feito por Park *et al.* (2024));
- Explorar erros sistemáticos do modelo e vocabulário associado à falha de compreensão.

2.7 Inclusão da Variável de Percentual de Acertos

Para enriquecer a análise preditiva e fornecer uma referência empírica direta ao desempenho humano em cada item, decidiu-se criar uma variável adicional que represente o *percentual de acertos observados* em uma amostra controlada de candidatos. Essa variável será obtida através da coleta de respostas de um grupo de 100 indivíduos (os mesmos 100 basearão as respostas de todas as questões de uma dada prova), aplicando-se a cada questão de Ciências da Natureza, e calculando-se, para cada item, a proporção de respostas corretas. Tais informações são retiradas dos microdados disponibilizados pelo INEP.

Como justificativa, enfatiza-se que, embora o parâmetro b da TRI forneça uma estimativa de dificuldade baseada em modelagem estatística sobre toda a população participante do ENEM, ele não reflete diretamente a percepção de dificuldade que um grupo externo de respondentes pode ter ao resolver o mesmo enunciado. Ao calcular o percentual de acertos em uma amostra de 100 pessoas previamente selecionadas, busca-se obter um valor empírico de dificuldade que complemente o parâmetro TRI, ao emular a etapa de pré-teste já existente na elaboração da prova.

Além disso, coletar respostas de 100 pessoas é relativamente rápido e factível em ambiente acadêmico ou em sala de aula, ou mesmo durante a etapa de pré-teste já realizada regularmente. Adicionalmente, ao padronizar o conjunto de respondentes (mesmo que pequeno) e documentar o processo de aplicação (local, instruções, tempo disponível),

garante-se que outros pesquisadores possam reproduzir a experiência em contextos semelhantes ou distintos. Dessa forma, qualquer comparação futura entre percentuais de acertos e parâmetros de dificuldade estará ancorada em metodologia clara e replicável.

2.8 Cálculo de Similaridades entre Embeddings

Como última variável imaginada, foram geradas quantificações de similaridade semântica entre o enunciado da questão, o texto do gabarito e o texto dos distratores, todas representadas por vetores de embedding de 300/100/50 dimensões. A ideia central é verificar o grau de proximidade vetorial entre os elementos textuais, de modo a capturar indicadores potenciais de “atração” ou “confusão” entre enunciado e opções de resposta.

Para cada item, dispõe-se das seguintes colunas :

- `enunciado_embeddings_word2vec_<300/100/50>`: vetor médio de 300/100/50 dimensões do enunciado da questão, calculado como a média dos embeddings de cada palavra (modelo Word2Vec pré-treinado pelo NILC).
- `gabarito_embeddings_word2vec_<300/100/50>`: vetor médio de 300/100/50 dimensões do texto da alternativa correta.
- `distratores_embeddings_word2vec_<300/100/50>`: vetor médio de 300/100/50 dimensões do texto concatenado de todos os distratores (alternativas incorretas), também obtido por média dos embeddings.

Fórmula da Similaridade de Cosseno

Para dois vetores $\mathbf{u}, \mathbf{v} \in R^{300/100/50}$, a similaridade de cosseno é definida como

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{\sum_{k=1}^{300} u_k v_k}{\sqrt{\sum_{k=1}^{300} u_k^2} \sqrt{\sum_{k=1}^{300} v_k^2}}.$$

O resultado varia no intervalo $[-1, 1]$, porém, como nossos embeddings Word2Vec tendem a apresentar componentes majoritariamente positivos, na prática as similaridades ficam em $[0, 1]$. Valores próximos a 1 indicam alta proximidade semântica, enquanto valores próximos a 0 indicam baixa similaridade.

2.9 Modelagem Preditiva

Dando início às abordagens de predição, no notebook **6. Modelos de Regressão.ipynb**, implementa-se modelos de regressão com aprendizagem de máquina para estimar o parâmetro de dificuldade (b) com base nas representações vetoriais.

Para este fim, utiliza-se um modelo de regressão linear como baseline, utilizando as bibliotecas `statsmodels` e `scikit-learn`, além da divisão dos dados em conjuntos de

treino e teste (80%-20%). O desempenho do modelo foi avaliado por meio da correlação entre valores previstos e reais de b , além de gráficos de resíduos. Também foi testado o método sugerido pelo artigo, de excluir outliers — parâmetros b maiores do que 3 ou menores do que -3.

Além do modelo linear proposto no artigo original, implementa-se, também, uma arquitetura neural baseada no modelo pré-treinado `neuralmind/bert-base-portuguese-cased`, aqui referida como *BertimbauRegressor*. Isso porque, conforme identificado por Nasir, Shaheen e Hoenkamp (2024), modelos de linguagem baseados em BERT têm se destacado como técnica de escolha para predição de dificuldade textual, sobretudo em domínios educacionais.

Em um breve resumo, o modelo consiste em duas camadas principais: (i) a camada BERT, responsável pela extração contextualizada de embeddings do enunciado da questão, e (ii) uma camada de regressão linear que recebe a representação do token [CLS] e estima o valor contínuo do parâmetro b . Como sugerido em (DEVLIN *et al.*, 2019), utilizou-se o otimizador `AdamW`, função de perda `MSELoss` e agendamento linear com aquecimento de aprendizado. O modelo foi treinado com 10 épocas, batch size 8 e *gradient clipping* de valor 2.

A escolha por essa abordagem se justifica por diversas razões:

- Como já dito, após revisão de Nasir, Shaheen e Hoenkamp (2024), verificou-se que modelos baseados em BERT superaram técnicas tradicionais (como TF-IDF, LDA, SVM, regressão logística) na maioria das tarefas de predição de dificuldade textual;
- A capacidade do BERT de capturar relações semânticas e sintáticas profundas do texto o torna mais robusto para tarefas que dependem de compreensão contextual (lembrando que o ENEM possui tal característica como destaque);
- Resultados empíricos mostraram menor RMSE em validação cruzada em comparação ao baseline linear, com estabilidade em múltiplas épocas de treinamento.

Sob todo esse contexto, o grupo entende que modelagem avança o paradigma inicial do artigo de Jaloto *et al.* (2023), afinal, acaba por incorporar embeddings contextuais treinados em larga escala sobre a língua portuguesa, ao invés da média de *word embeddings* estáticos. Por fim, os resultados do modelo BERT serão utilizados como comparação direta com as regressões tradicionais.

3 ANÁLISE EXPLORATÓRIA

A fim de enriquecer o conhecimento a respeito da base objeto do estudo, apresenta-se investigação descritiva das provas após o pré-processamento textual das questões. Apesar de o objetivo principal ser compreender melhor alguns padrões intuitivos, também tem como condão a identificação de padrões estatísticos relevantes e mais avançados, especialmente o parâmetro de dificuldade (b).

3.1 Distribuição do Parâmetro de Dificuldade

Conforme verificável na Figura 3, utilizada para a apresentação da frequência intervalar da variável **Dificuldade** — correspondente ao parâmetro b da Teoria da Resposta ao Item — o gráfico demonstra uma leve assimetria à direita e picos na região central. Ou seja, possível apreender que a maioria das questões possui dificuldade moderada. Contudo, não é possível ignorar o fato de que uma das questões atingiu pontuação superior a 8, diferenciando-se do padrão.




Figura 3 – Distribuição geral do parâmetro de dificuldade (b) das questões.

Ato contínuo, optou-se por analisar o comportamento da mesma variável diante da ausência do que Jaloto *et al.* (2023) consideraram como *outliers* — todas as questões que não estão com dificuldade dentro do intervalo -3 e 3 . O resultado pode ser visualizado na Figura 4. A distribuição, por contar com uma menor amplitude, evidencia que o comportamento não é tão similar a uma Normal, como parecia no gráfico anterior.




Figura 4 – Distribuição do parâmetro de dificuldade (b) filtrado no intervalo $[-3, 3]$.

3.2 Verificação de Normalidade

Ato contínuo, uma vez que será realizada uma regressão linear, recomenda-se o estudo da normalidade. Em um primeiro momento, por meio do Q-Q plot (Figura 5). Observa-se que os dados seguem aproximadamente uma linha reta, com desvios leves nas extremidades — sugerindo distribuição aproximadamente normal com presença de poucos outliers à direita.




Figura 5 – Q-Q plot do parâmetro de dificuldade (b).

Contudo, ao adentrar método de normalidade mais rigoroso, Shapiro-Wilk, verifica-se que o p-valor é de aproximadamente $5 \cdot 10^{-6}$. Em outras palavras, há evidência suficiente

para excluir a hipótese nula de normalidade da distribuição. Logo, passa a ser um ponto de atenção para etapas futuras do trabalho.

3.3 Questões por Ano de Aplicação

A Figura 6 mostra a quantidade de questões disponíveis por ano na base de dados. O ideal, de 45 questões por ano, é destacado por uma linha tracejada vermelha. Verifica-se que até o ano de 2014 há certa inconsistência na quantidade, o que se trata de consequência direta do realizado na etapa de pré-processamento, de exclusão de questões que não possuam alternativas com padrão mínimo de qualidade. Também não se pode esquecer o fato de que em muitos anos há anulação de questões.




Figura 6 – Número de questões disponíveis por ano de aplicação.

Já a Figura 7 apresenta a distribuição do parâmetro de dificuldade ao longo dos anos. A variação interquartílica é relativamente estável entre os períodos, com presença de outliers em todos os estudados - ou seja, usualmente a prova tende a possuir uma questão com maior nível de facilidade. Ainda, destacam-se os outliers de 8 e 6 pontos, aproximadamente. No mais, não há evidência de tendência temporal consistente.




Figura 7 – Boxplot do parâmetro b por ano de aplicação.

3.4 Distribuição das Alternativas Corretas

A Figura 8 exibe a frequência das alternativas corretas (gabaritos) na base. As alternativas D, B e C aparecem com maior frequência, enquanto A e E são as menos recorrentes. Essa assimetria pode refletir preferências editoriais ou distribuição aleatória não balanceada — sem perder de vista questões que não estão presentes nesta análise.




Figura 8 – Distribuição das alternativas corretas (gabaritos).

3.5 Distribuição do Tamanho dos Enunciados e Gabaritos

A Figura 9, por sua vez, apresenta a distribuição do tamanho dos enunciados, antes e depois do pré-processamento. Observa-se que a limpeza textual resultou em enunciados mais curtos e com menor variabilidade. A distribuição manteve assimetria à direita em ambos os casos, sendo ligeiramente mais concentrada após a remoção de palavras e caracteres — o que, de certa forma, já é esperado. Contudo, ainda assim, ressalta-se uma certa padronização em tamanhos intermediários.




Figura 9 – Distribuição do tamanho dos enunciados (original e pré-processado).

A mesma análise foi realizada para os textos das alternativas corretas (gabaritos). Conforme mostra a Figura 10, a maioria dos gabaritos possui menos de 100 caracteres, apresentando padrão similar antes e depois do pré-processamento.




Figura 10 – Distribuição do tamanho dos gabaritos (original e pré-processado).

3.6 Relação entre Tamanho e Dificuldade

A Figura 11 apresenta a dispersão entre o tamanho dos enunciados e o parâmetro b , tanto na versão original quanto após pré-processamento. Em ambas as representações, não há correlação linear clara, embora enunciados muito longos apresentem certo piso na dificuldade — apesar de não serem os que se destacam pela maior dificuldade.




Figura 11 – Relação entre tamanho do enunciado e dificuldade (b).

A relação entre o tamanho do gabarito e o parâmetro b é mostrada na Figura 12. Os resultados indicam que textos muito longos como resposta correta tendem a ser menos comuns, mas não se observa relação direta com a dificuldade.




Figura 12 – Relação entre tamanho do gabarito e dificuldade (b).

3.7 Frequência e Padrões de Palavras

As Figuras 13, 14 e 15 mostram os histogramas de palavras mais frequentes nos enunciados, gabaritos e distratores, segmentados por dificuldade.




Figura 13 – Palavras mais frequentes nos enunciados, separadas por dificuldade.




Figura 14 – Palavras mais frequentes nos gabaritos, separadas por dificuldade.




Figura 15 – Palavras mais frequentes nos distratores, separadas por dificuldade.

Observa-se que palavras como “água”, “maior”, “energia” e “quantidade” aparecem de forma recorrente em todos os níveis de dificuldade, indicando vocabulário comum na área de Ciências da Natureza. No entanto, termos como “dois”, “zero” e “fórmula química” aparecem com mais frequência em itens difíceis, o que pode dar um norte para o fato de que questões com vocabulários mais técnicos e/ou quantitativos gerem maior dificuldade.

3.8 Nuvens de Palavras por Dificuldade

As Figuras 16, 17 e 18, em verdade, podem ser interpretadas como visualizações de outra perspectiva com o mesmo escopo das anteriores. Ou seja, evidenciam nuvens

de palavras para enunciados, gabaritos e distratores, respectivamente. As palavras foram separadas com base em um limiar de dificuldade ($b = 1.39$), conforme a média empírica.




Figura 16 – Nuvens de palavras dos enunciados: geral, difícil (> 1.39) e fácil (≤ 1.39).




Figura 17 – Nuvens de palavras dos gabaritos: geral, difícil (> 1.39) e fácil (≤ 1.39).




Figura 18 – Nuvens de palavras dos distratores: geral, difícil (> 1.39) e fácil (≤ 1.39).

As palavras mais frequentes nos itens difíceis tendem a se associar a conceitos técnicos ou quantitativos, novamente, como “dois”, “maior”, “resistência” e “fórmula”. Já itens mais fáceis utilizam vocabulário mais comum e cotidiano, como “água”, “ambiente”, “produção” e “energia”.

4 MODELOS E RESULTADOS

A fim de iniciar esse capítulo, esclarece-se que todas as variáveis mencionadas no capítulo de metodologia foram utilizadas. Salienta-se que os modelos também foram executados sem estas, contudo sem a mesma performance obtida.

4.1 Compreensão de conceitos: R^2 e $RMSE$

4.1.1 Definições

Antes de dar continuidade aos trabalhos, importa familiarizar o leitor, também, com conceitos que serão utilizados para metrificar o sucesso de cada um dos modelos. E, aqui, será almejado explicar não apenas o R^2 , utilizado no artigo original, como também o $RMSE$. Tudo a fim de que fique o mais claro possível o intuito do grupo na conclusão final.

Assim, a *Raiz do Erro Quadrático Médio* (RMSE) matematicamente é definida como

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

onde y_i são os valores observados e $\hat{y}_i$ os valores preditos pelo modelo.

O coeficiente de determinação R^2 , por sua vez, é dado por

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{SS_{\text{reg}}}{SS_{\text{tot}}},$$

onde $\bar{y}$ é a média dos valores observados, conquanto y_i e $\hat{y}_i$ são conceitualmente idênticos.

4.1.2 Comparação Conceitual

Atentando-se à escala do resultado obtido em cada uma, o RMSE mantém a unidade original da variável y , facilitando, assim, a interpretação das discrepâncias absolutas (WILLMOTT; MATSUURA, 2005). Por outro lado, o R^2 é adimensional, carregando consigo uma proporção de variância explicada sem depender da escala; de acordo com a literatura (MONTGOMERY; PECK; VINING, 2012), trata-se da proporção de variação explicada pelo regressor.

A respeito do intervalo e da sensibilidade de cada uma das estatísticas, enfatiza-se que o RMSE varia em $[0, \infty)$, sensibilizando-se fortemente por outliers devido à quadratura dos erros (WILLMOTT; MATSUURA, 2005). Em contrapartida, o R^2 varia em $[0, 1]$ em regressões com intercepto (< 0 ou > 1 em casos especiais); ou seja, por se tratar de medida relativa, acaba por não capturar a magnitude dos resíduos.

Sobre sua interpretação, são conceitos invertidos. Em melhores palavras, um RMSE menor indica maior precisão absoluta na previsão; conquanto, um R^2 maior significa que porcentagem superior da variabilidade total em y é explicada pelas variáveis do modelo (MONTGOMERY; PECK; VINING, 2012).

Enfim, como salienta Montgomery, Peck e Vining (2012), a inclusão de novas variáveis ao modelo preditor tendem a aumentar o R^2 . Ou seja, no caso em tela, deve-se tomar extrema cautela com tal abordagem, na medida em que serão utilizadas 300 variáveis para a predição.

4.1.3 Limitações e Uso Conjunto

Nesse contexto, nenhuma das duas métricas é suficiente isoladamente. Recomenda-se usar RMSE para avaliar erro médio em unidades reais e R^2 para medir poder explicativo. Seu estudo deverá ser em conjunto em virtude de o R^2 poder causar falsa sensação de segurança devido à quantidade de variáveis utilizadas, de modo que o $RMSE$ remeterá à medida real do erro.

4.2 Modelos de Regressão com *Word Embeddings*

4.2.1 Base Integral e Sem Estudo de Similaridades

Nesta etapa, investigou-se a possibilidade de predizer o parâmetro de dificuldade (b) dos itens de Ciências da Natureza com base apenas em suas representações textuais vetorizadas. Para isso, foram utilizados embeddings pré-treinados do tipo `word2vec`, aplicados ao enunciado dos itens, com três diferentes dimensionalidades: 300, 100 e 50. Para cada uma dessas representações, ajustaram-se dois modelos de regressão: regressão linear múltipla (OLS) e regressão com regularização Lasso.

A variável resposta passou por transformação de Box-Cox, sendo necessário o deslocamento dos valores a fim de garantir sua positividade. Curiosamente, a transformação resultou no mesmo parâmetro ótimo em todos os casos ($\lambda \approx 0,612$), o que indica certa estabilidade na distribuição dos valores de b após o ajuste.

A Tabela 1 apresenta os valores de R^2 , R^2_{ajustado} e RMSE obtidos para cada uma das três dimensionalidades de embeddings, em ambos os métodos:

Tabela 1 – Desempenho dos Modelos de Regressão

Modelo	Dimensões	R^2	R^2_{ajustado}	RMSE
Regressão Linear	300	0,749	0,131	0,976
Regressão Linear	100	0,339	0,134	0,586
Regressão Linear	50	0,221	0,116	0,536
Regressão Lasso	300	0,294	—	0,510
Regressão Lasso	100	0,197	—	0,507
Regressão Lasso	50	0,156	—	0,499

Embora o modelo com 300 dimensões apresente o maior R^2 nominal na regressão linear, o valor ajustado e, principalmente, o RMSE elevado sugerem que houve sobreajuste, causado pela alta quantidade de variáveis em relação ao número de observações. Em contraste, os modelos com 100 e 50 dimensões, apesar de explicarem menos variância (R^2 inferior), demonstraram melhor desempenho absoluto na previsão, como evidenciado pelos menores valores de RMSE.

A regressão com penalização Lasso, por sua vez, apresentou consistentemente menores valores de RMSE em comparação à regressão linear correspondente. Isso evidencia a capacidade do método de regularização de reduzir o sobreajuste, selecionando automaticamente um subconjunto de variáveis mais relevantes. Nota-se também que, para todas as dimensionalidades, o hiperparâmetro α ótimo encontrado foi 0,001.

Portanto, os resultados reforçam a importância de se considerar não apenas a variância explicada, mas também o erro absoluto na avaliação de modelos. Ademais, evidenciam que a redução da dimensionalidade — e o uso de métodos de regularização — podem ser estratégias eficazes para melhorar a capacidade preditiva e a generalização, sobretudo quando se trabalha com representações textuais de alta dimensionalidade.

4.2.2 Modelos com Exclusão de Outliers e Sem Estudo de Similaridades

Seguindo a metodologia do artigo de referência, procedeu-se com a exclusão dos itens cujo parâmetro de dificuldade (b) era inferior a -3 ou superior a 3 . De acordo com Jaloto *et al.* (2023), o intuito seria mitigar influências extremas no modelo.

Assim, ajustados para as três dimensionalidades de embeddings: 50, 100 e 300. A Tabela 2 apresenta os valores de R^2 , R^2_{ajustado} e RMSE dos modelos lineares, bem como o desempenho dos modelos com regularização Lasso.

Tabela 2 – Desempenho dos modelos com exclusão de outliers

Modelo	Dimensões	R^2	R^2_{ajustado}	RMSE
Regressão Linear	300	0,800	0,264	3,883
Regressão Linear	100	0,364	0,161	2,367
Regressão Linear	50	0,222	0,115	2,012
Regressão Lasso	300	0,119	—	1,933
Regressão Lasso	100	0,102	—	1,962
Regressão Lasso	50	0,113	—	1,959

Observa-se que a exclusão dos outliers resultou em um ganho substancial no valor de R^2 para a regressão linear com 300 dimensões ($R^2 = 0,800$) e melhora relativa nos demais casos. Por outro lado, o RMSE aumentou de forma significativa quando comparado aos modelos anteriores com os dados completos.

Os modelos Lasso apresentaram desempenho relativamente constante, com R^2 mais modestos mas valores de RMSE consideravelmente inferiores aos obtidos pela regressão linear.

De forma geral, a abordagem de excluir os outliers revelou-se alinhada à proposta do artigo original. Contudo, notável que impactos no RMSE denotam que a exclusão de dados extremos acabam por prejudicar o modelo. Desta maneira, não apenas não se visualiza razões para os excluir (dado não serem dados coletados com erros, mas comportamentos esperados de uma prova), como ainda se verifica perda de eficiência da modelagem.

4.2.3 Modelos com Similaridades Semânticas e Acertos do LLM

Concluindo as regressões utilizadas, a última etapa consistiu na incorporação como variáveis preditoras medidas de similaridade semântica entre o enunciado dos itens e suas alternativas, além do acerto das LLM e porcentagem de acerto dos alunos. É interessante mencionar que o Llama3.2 acertou 171 das 605 questões, enquanto o DeepSeek, por ser um modelo de raciocínio com maior número de parâmetros (isto é, "pensa" por alguns segundos antes de retornar uma resposta final), acertou 399.

As regressões foram ajustadas com as mesmas três dimensionalidades dos embeddings: 300, 100 e 50. A Tabela 3 resume os resultados obtidos com regressão linear e com regressão Lasso:

Tabela 3 – Desempenho dos modelos com medidas de similaridade semântica

Modelo	Dimensões	R^2	R^2_{ajustado}	RMSE
Regressão Linear	300	0,816	0,330	0,844
Regressão Linear	100	0,506	0,341	0,517
Regressão Linear	50	0,423	0,335	0,465
Regressão Lasso	300	0,446	—	0,436
Regressão Lasso	100	0,390	—	0,431
Regressão Lasso	50	0,360	—	0,420

Os resultados indicam que a adição das medidas de similaridade semântica foi benéfica, principalmente nos modelos de menor dimensionalidade. A regressão linear com 50 dimensões e similaridade, por exemplo, atingiu $R^2 = 0,423$ e RMSE de 0,465, superando o desempenho da versão sem essas features.

Já os modelos com Lasso também se beneficiaram da nova representação, com melhorias consideráveis em todos os valores de R^2 e redução do RMSE. O Lasso com 300 dimensões e similaridade, por exemplo, obteve $R^2 = 0,446$ e RMSE de 0,436, representando o melhor equilíbrio entre explicação e erro preditivo entre todos os modelos apresentados até então.

Tais resultados reforçam a hipótese de que a estrutura semântica entre enunciado e alternativas tem papel importante na dificuldade percebida do item. Incorporar essas relações permite capturar nuances que não estão presentes apenas na média dos embeddings, aumentando a capacidade explicativa dos modelos.

4.3 Modelo *BERT* regressor

4.3.1 Construção e funcionamento do modelo

O *BERT* (Bidirectional Encoder Representations from Transformers) é um modelo de linguagem neural desenvolvido pelo Google em 2018, que revolucionou o ramo do processamento de linguagem natural. Diferente de modelos anteriores, que analisavam textos de forma unidirecional (da esquerda para a direita ou vice-versa), o *BERT* é bidirecional, ou seja, ele considera o contexto completo das palavras em ambas as direções. Isso permite uma compreensão mais profunda do significado das palavras em frases, tornando-o especialmente eficaz para tarefas como tradução, classificação de texto e resposta a perguntas.

O funcionamento do *BERT* baseia-se na arquitetura *Transformer*, que utiliza camadas de autoatenção para analisar as relações entre todas as palavras de uma sentença simultaneamente. Por esse motivo, os dados utilizados neste modelo não passam pela etapa de pré processamento em que *stopwords*, pontuações e números são removidos do enunciado, já que o modelo precisa de todo o contexto do enunciado para identificar tais

padrões. Durante o pré-treinamento, o modelo aprende a prever palavras mascaradas (masked language modeling) e a identificar a relação entre frases (next sentence prediction).

Após o pré-treinamento, o *BERT* pode ser ajustado (*fine-tuning*) para tarefas específicas com poucos exemplos, graças à sua capacidade de generalização. Nesta tarefa, ajustamos o modelo para realizar a tarefa de regressão, adicionando uma camada regressora extra na extremidade de saída da rede.

4.3.2 Resultados

Após o treinamento de 100 épocas, o modelo alcançou o valor de RMSE de 0,97 e, portanto, não conseguiu resultados melhores que boa parte dos métodos de regressão aplicados. Esse resultado pode ser explicado pelo baixo volume de dados utilizados, uma vez que modelos baseados em *Transformers* precisam de uma grande quantidade de dados para treinamento e *fine-tuning*, e os poucos textos à nossa disposição não foram suficientes.

A Figura 19 apresenta as curvas de valor da função *loss* dos dados de treino e teste ao longo das épocas treinadas. O padrão obtido na curva de teste ocorre quando os dados utilizados não são representativos em relação ao escopo do problema, um obstáculo muito comum em casos em que a quantidade de dados é insuficiente para alcançar um bom resultado.




Figura 19 – Curva de função *loss* de treino e teste

5 CONCLUSÃO

Diante de todo o exposto, o trabalho investigou a possibilidade de se estimar o parâmetro de dificuldade (b) de itens do Exame Nacional do Ensino Médio (ENEM) a partir de suas representações textuais, utilizando técnicas de Processamento de Linguagem Natural (PLN) e modelagem preditiva.

A partir da extração e pré-processamento de mais de uma década de provas da área de Ciências da Natureza, construiu-se um conjunto de dados estruturado contendo os enunciados, alternativas, gabaritos e parâmetros de desempenho em amostras dos itens. Com isso, aplicaram-se modelos de regressão para prever a dificuldade dos itens com base em embeddings médios do enunciado, bem como medidas complementares de similaridade semântica.

Os experimentos revelaram ser possível recuperar parte substancial da variação do parâmetro b utilizando apenas informações textuais dos itens. Destacam-se, dentre os achados:

- A regressão linear com 300 dimensões apresentou o maior R^2 nominal, porém com elevado RMSE e risco de sobreajuste. Já as regressões com 50 e 100 dimensões mostraram melhor desempenho absoluto (menor RMSE), sugerindo que modelos mais enxutos tendem a generalizar melhor.
- Os modelos com regularização Lasso foram eficazes na redução de erro absoluto e mostraram-se especialmente robustos nas configurações com maior número de variáveis, confirmando sua utilidade em contextos com alta dimensionalidade, punindo variáveis de menor colaboração.
- A exclusão de outliers, apesar de recomendada no artigo original, levou a aumentos significativos no RMSE, sem ganho proporcional em R^2_{ajustado} , o que sugere que essa prática pode prejudicar a performance preditiva e eliminar casos importantes para a modelagem da complexidade dos itens.
- A inclusão de variáveis de similaridade semântica entre enunciado e alternativas melhorou consideravelmente a capacidade explicativa dos modelos, elevando tanto o R^2 quanto reduzindo o RMSE. Tais variáveis capturam aspectos sutis da estrutura textual que não são plenamente representados por embeddings médios.
- Os melhores resultados foram observados com o uso conjunto de embeddings e medidas de similaridade semântica, especialmente nos modelos com regressão Lasso com 50 dimensões, que alcançaram RMSE próximo a 0,42.

- O resultado obtido pelo modelo regressor *BERT* não conseguiu superar a maior parte dos modelos de regressão pelo baixo volume de dados à sua disposição.

Dessa forma, o trabalho explorou a hipótese de que é possível estimar a dificuldade de questões de maneira automatizada, utilizando informações extraídas do texto da prova, além de observar a possibilidade de menor grupo de amostra em pré-testes. Ainda que os modelos apresentem limitações, como a dificuldade em capturar contextos dependentes de imagens ou gráficos, os resultados obtidos oferecem base para a construção de sistemas de avaliação assistida e metodologias de pré-testagem mais econômicas e seguras.

Como perspectivas futuras, destacam-se:

- A inclusão de variáveis baseadas em desempenho de outras LLMs na resolução direta dos itens, o que permitirá comparar dificuldade empírica com dificuldade percebida por modelos, na tentativa de emular uma maior diversidade de alunos;
- A replicação do estudo em outras áreas do conhecimento, a fim de verificar a robustez da abordagem em domínios com diferentes estilos de questão.

Desta forma, o trabalho mostra que representações linguísticas vetoriais e técnicas de regressão modernas são ferramentas promissoras para a modelagem da dificuldade de itens, e podem contribuir para a construção de avaliações mais precisas, eficientes e seguras.

REFERÊNCIAS

- DEVLIN, J. *et al.* Bert: Pre-training of deep bidirectional transformers for language understanding. **arXiv preprint arXiv:1810.04805**, 2019. Acesso em: 02 jun. 2025. Disponível em: <https://arxiv.org/abs/1810.04805>.
- GRATTAFIORI, A.; DUBEY, A.; JAUHRI, A. The llama 3 herd of models. **arXiv preprint arXiv:2407.21783**, 2024. Acesso em: 24 mai. 2025. Disponível em: <https://arxiv.org/abs/2407.21783>.
- GUO, D. *et al.* Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. **arXiv preprint arXiv:2501.12948**, 2025. Acesso em: 24 mai. 2025. Disponível em: <https://arxiv.org/abs/2501.12948>.
- HARTMANN, N. *et al.* **Portuguese Word Embeddings: Evaluating on Word Analogies and Natural Language Tasks**. 2017. <http://arxiv.org/abs/1708.06025>. ArXiv:1708.06025 [cs], Acesso em: 30 abr. 2025.
- Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Entenda a sua nota no Enem: guia do participante**. 2021. https://download.inep.gov.br/publicacoes/institucionais/avaliacoes_e_exames_da_educacao_basica/entenda_a_sua_nota_no_enem_guia_do_participante.pdf. Acesso em: 30 abr. 2025.
- Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Microdados do Enem**. 2025. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>. Acesso em: 30 abr. 2025.
- JALOTO, A. *et al.* **É possível calibrar os itens do Enem sem pré-teste?** 2023. <https://www.even3.com.br/anais/xiiabave/661223-e-possivel-calibrar-os-itens-do-enem-sem-pre-teste/>. Acesso em: 30 abr. 2025.
- MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. **Introduction to Linear Regression Analysis**. Hoboken, NJ: John Wiley & Sons, 2012.
- NASIR, M.; SHAHEEN, E.; HOENKAMP, E. Text-based question difficulty prediction: A systematic review of automatic approaches. **International Journal of Artificial Intelligence in Education**, 2024. Acesso em: 24 mai. 2025. Disponível em: <https://link.springer.com/article/10.1007/s40593-023-00362-1>.
- PARK, J.-W. *et al.* Large language models are students at various levels: Zero-shot question difficulty estimation. *In: Findings of the Association for Computational Linguistics: EMNLP 2024*. Association for Computational Linguistics, 2024. p. 8157–8177. Acesso em: 24 mai. 2025. Disponível em: <https://aclanthology.org/2024.findings-emnlp.477>.
- WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (mae) over the root mean squared error (rmse) in assessing average model performance. **Climate Research**, v. 30, n. 1, p. 79–82, 2005.

YANEVA, V. *et al.* Automated prediction of difficulty and response time for multi-choice questions. *In: Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA)*. Association for Computational Linguistics, 2024. p. 1–17. Acesso em: 24 mai. 2025. Disponível em: <https://aclanthology.org/2024.bea-1.39>.